



UNIVERSITATEA BABEȘ-BOLYAI
Facultatea de Matematică și Informatică



INTELIGENȚĂ ARTIFICIALĂ

Sisteme inteligente

Sisteme care învață singure

Laura Dioșan

Sumar

A. Scurtă introducere în Inteligența Artificială (IA)

B. Rezolvarea problemelor prin căutare

- Definirea problemelor de căutare
- Strategii de căutare
 - Strategii de căutare neinformate
 - Strategii de căutare informate
 - Strategii de căutare locale (Hill Climbing, Simulated Annealing, Tabu Search, Algoritmi evolutivi, PSO, ACO)
 - Strategii de căutare adversială

C. Sisteme inteligente

- Sisteme care învață singure
 - Arbori de decizie
 - Rețele neuronale artificiale
 - Mașini cu suport vectorial
 - Algoritmi evolutivi
- Sisteme bazate pe reguli
- Sisteme hibride

Materiale de citit și legături utile

- ❑ capitolul VI (18) din *S. Russell, P. Norvig, Artificial Intelligence: A Modern Approach, Prentice Hall, 1995*
- ❑ capitolul 10 și 11 din *C. Groșan, A. Abraham, Intelligent Systems: A Modern Approach, Springer, 2011*
- ❑ capitolul V din *D. J. C. MacKey, Information Theory, Inference and Learning Algorithms, Cambridge University Press, 2003*
- ❑ capitolul 3 din *T. M. Mitchell, Machine Learning, McGraw-Hill Science, 1997* [link](#)
- ❑ capitolul 1 din *C. Bishop, Pattern Recognition and Machine Learning, Springer, 2006* [link](#)
- ❑ capitolul 1 din *S. Guido, A. C. Müller, Introduction to Machine Learning with Python, O'Reilly Media, 2016* [link](#)
- ❑ capitolele 1 și 2 din *A. Geron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, O'Reilly Media, 2019* [link](#)

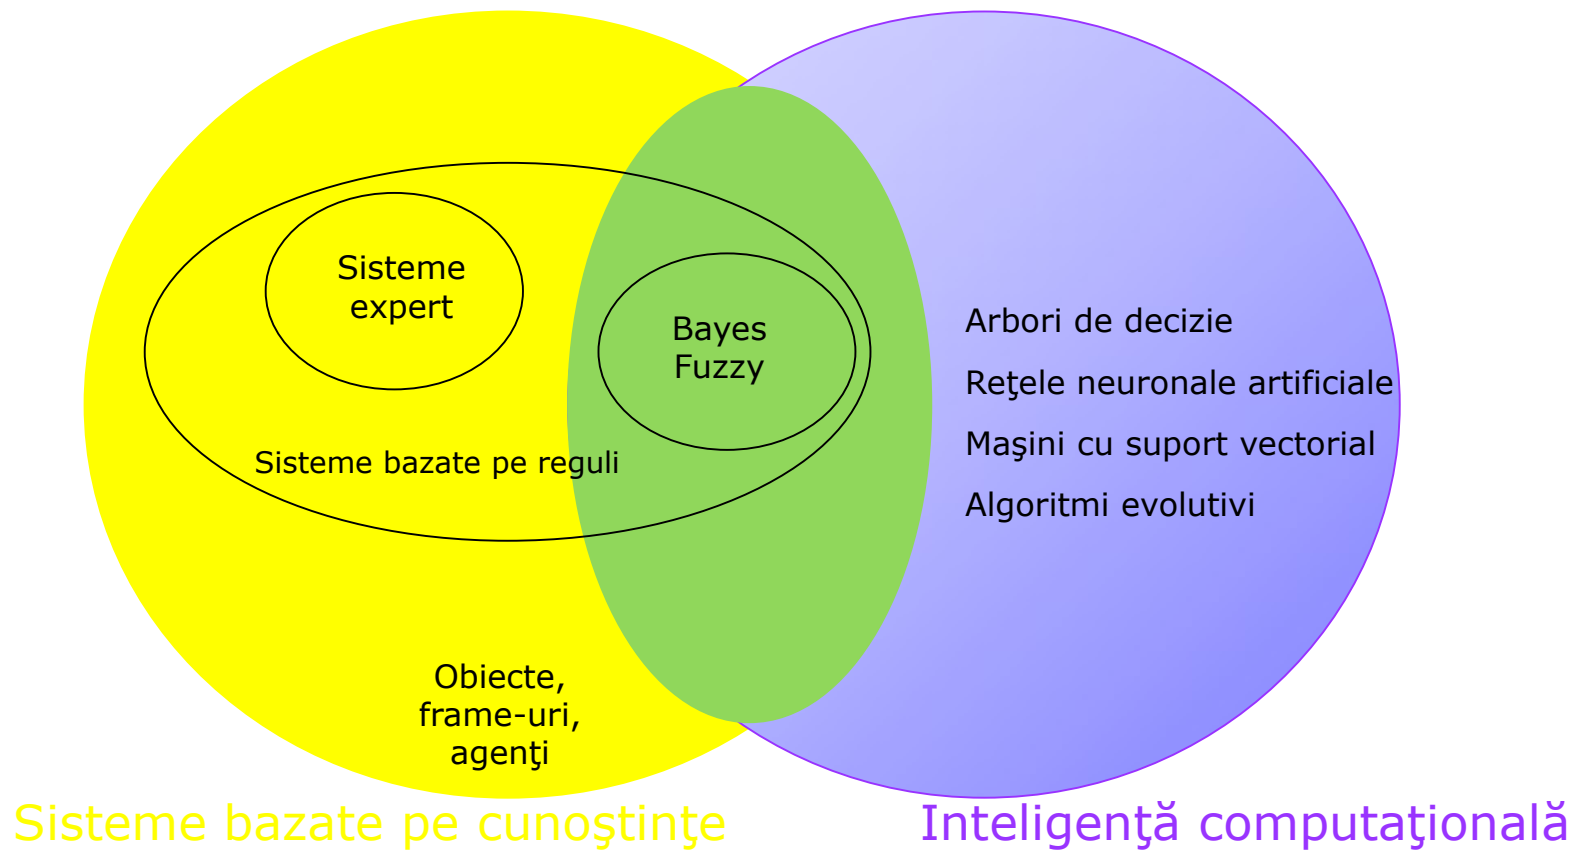
Conținut

□ Sisteme inteligente

■ Sisteme care învață singure (SIS)

- Instruire (învățare) automata (Machine Learning - ML)
 - Problematică
 - Proiectarea unui sistem de învățare automată
 - Tipologie
 - Învățare supervizată
 - Învățare nesupervizată
 - Învățare cu întărire
 - Teoria învățării
- Exemple de sisteme

Sisteme inteligente



Sisteme inteligente – SIS – Învățare automată

□ Problematica

- “How can we build computer systems that automatically improve with experience, and what are the fundamental laws that govern all learning processes?”

□ Aplicații

- Recunoaștere de imagini și semnal vocal
 - Recunoașterea scrisului de mână
 - Detecția fețelor
 - Înțelegerea limbajului vorbit
- Computer vision
 - Detecția obstacolelor
 - Recunoașterea amprentelor
- Supraveghere bio
- Controlul roboților
- Predicția vremii
- Diagnosticare medicală
- Detecția fraudelor

Sisteme inteligente – SIS – Învățare automată

□ Definire

- Arthur Samuel (1959)
 - "field of study that gives computers the ability to learn without being explicitly programmed"
 - Înzestrarea computerelor cu abilitatea de a învăța pe baza experienței
- Herbert Simon (1970)
 - "Learning is any process by which a system improves performance from experience."
- Tom Mitchell (1998)
 - "a well-posed learning problem is defined as follows: He says that a computer program is set to learn from an experience E with respect to some task T and some performance measure P if its performance on T as measured by P improves with experience E"
- Ethem Alpaydin (2010)
 - Programming computers to optimize a performance criterion using example data or past experience.
- John L. Hennessy, President of Stanford (2000–2016)
 - Machine learning is the hot new thing
- Bill Gates (Microsoft co-founder)
 - A breakthrough in machine learning would be worth ten Microsofts

□ Necesitate

- Sisteme computaționale mai bune
 - Sisteme dificil sau prea costisitor de construit manual
 - Sisteme care se adaptează automat
 - Filtre de spam
 - Sisteme care descoperă informații în baze de date mari → data mining
 - Analize financiare
 - Analize de text/imagini
- Înțelegerea organismelor biologice

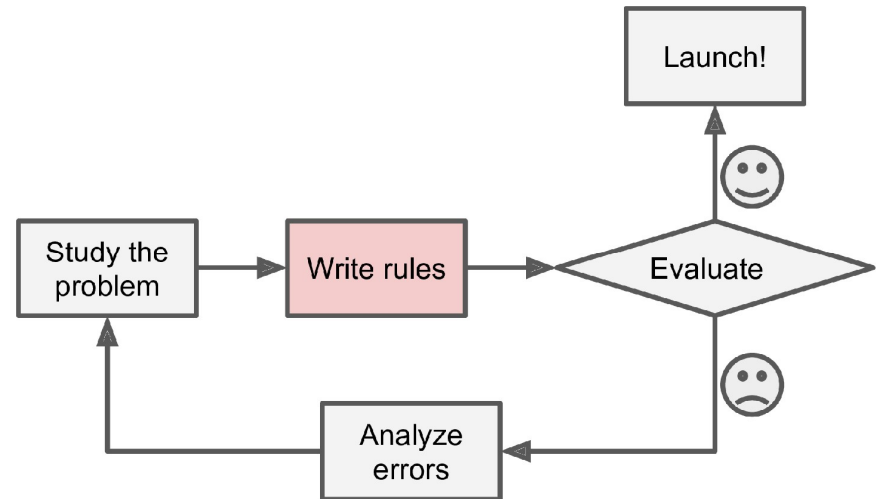



Sisteme inteligente – SIS – Învățare automată

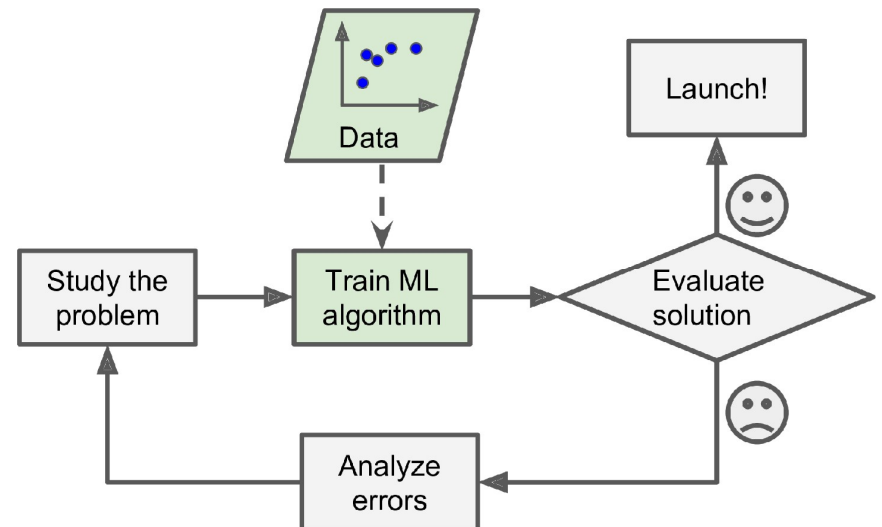
- Persoane importante și/sau interesante
 - Peter Norvig
 - Stuart Russell
 - Michael Jordan (Bayesian Nets), Andrew Ng
 - Elon Musk, Andrej Karpathy (TESLA)
 - Fei Fei Li (AI for social good)
 - Richard Sutton (Reinforcement Learning)
 - Jurgen Schmidhuber (LSTM)
 - Geoffrey Hinton , Yann LeCun, and Yoshua Bengio (CNN and deep CNN)
 - John Koza (Genetic Programming)
 - Rana el Kaliouby (Affectiva)
 - ...alții...

Sisteme inteligente – SIS – Învățare automată

□ Programarea tradițională



□ Machine Learning



Sisteme inteligente – SIS – Învățare automată

□ Proiectare

■ Îmbunătățirea task-ului T

- Stabilirea scopului (ceea ce trebuie învățat) - funcției obiectiv – și reprezentarea sa
- Alegerea unui algoritm de învățare care să realizeze inferența (previziunea) scopului pe baza experienței

■ respectând o metrică de performanță P

- Evaluarea performanțelor algoritmului ales

■ bazându-se pe experiența E

- Alegerea bazei de experiență

■ Exemplu

- T: jucarea jocului de dame
- P: procentul de jocuri câștigate împotriva unui oponent oarecare
- E: exersarea jocului împotriva lui însuși

- T: recunoașterea scrisului de mână
- P: procentul de cuvinte recunoscute corect
- E: baze de date cu imagini cu cuvinte corect adnotate

- T: separarea spam-urilor de mesajele obișnuite
- P: procentul de email-uri corect clasificate (spam sau normal)
- E: baze de date cu email-uri adnotate

Sisteme inteligente – SIS – Învățare automată

□ Stabilirea scopului (ceea ce trebuie învățat)


■ SI pentru predicții / regresii

- Scop: predicția ieșirii pentru o intrare nouă folosind un model învățat anterior
- Ex.: predicția vânzărilor dintr-un produs pentru un moment de timp viitor în funcție de preț, lună calendaristică, regiune, venit mediu pe economie




■ SI pentru regresii simbolice

- Scop: estimarea formei unei funcții uni sau multivariată folosind un model învățat anterior
- Ex.: estimarea funcției care modelează conturul unei suprafețe



■ SI pentru clasificare

- Scop: clasificarea unui obiect într-una sau mai multe categorii (clase) – cunoscute anterior sau nu - pe baza caracteristicilor (atributelor, proprietăților) lui
- Ex.: sistem de diagnostică pentru un pacient cu tumoare: nevasculară, vasvulară, angiogenă



■ SI pentru planificare

- Scop: generarea unei succesiuni optime de acțiuni pentru efectuarea unei sarcini
- Ex.: planificarea deplasării unui robot de la o poziție dată până la o sursă de energie (pentru alimentare)



Sisteme inteligente – SIS – Învățare automată

□ Stabilirea scopului (ceea ce trebuie învățat)

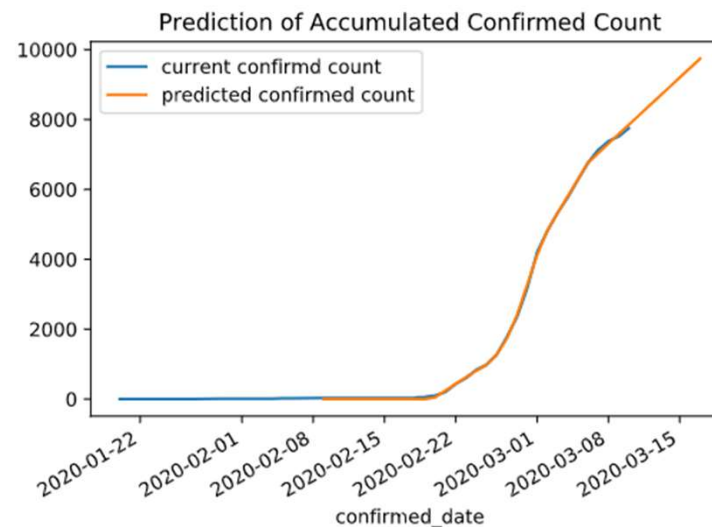

■ Probleme de predicție / regresie

□ Se dau date (de intrare și ieșire) trecute

- Numărul de persoane infectate cu SARS-CoV-2 pentru ultimele 3 luni



□ Se cer predicții viitoare (pentru anumite date de intrare)

- Numărul de persoane care se vor infecta cu SARS-CoV-2 în următoarele 7 zile / 4 săptămâni / 2 luni



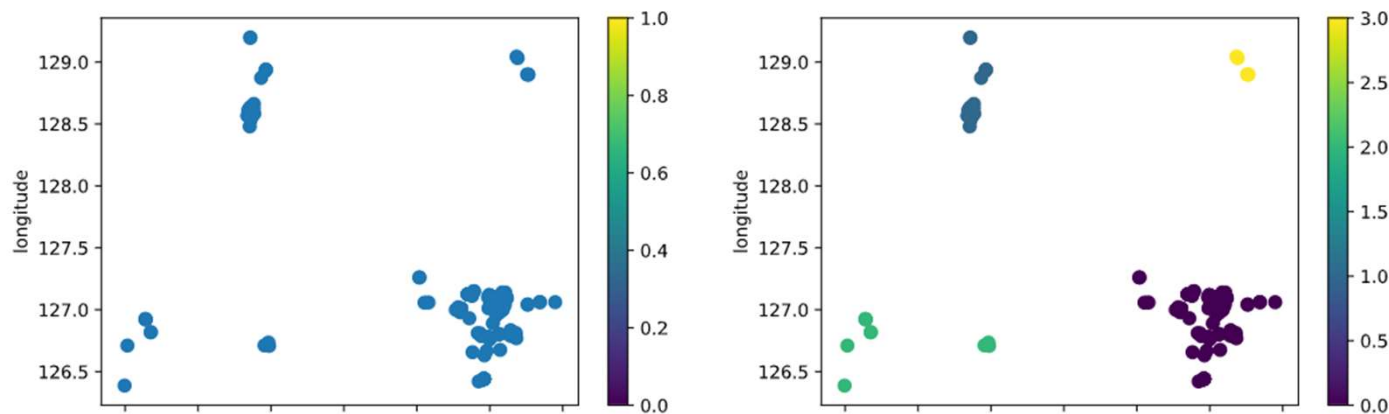
Sisteme inteligente – SIS – Învățare automată

- ❑ Stabilirea scopului (ceea ce trebuie învățat)
 - Probleme de clasificare
 - ❑ Se dau date (de intrare și ieșire) trecute
 - Imagini RMN de la pacienți infectați cu SARS-CoV-2 și de la martori (sănătoși)
 - ❑ Se cer predicții viitoare (pentru anumite date de intrare)
 - Să se prezică, pe baza RMN-ului, dacă o persoană este infectată sau nu cu SARS-CoV-2



Sisteme inteligente – SIS – Învățare automată

- ❑ Stabilirea scopului (ceea ce trebuie învățat)
 - Probleme de clusterizare
 - ❑ Se dau date (de intrare)
 - Localizarea geografică a unor persoane infectate cu SARS-CoV-2
 - ❑ Se cere identificarea anumitor structuri în aceste date
 - Modul de grupare a celor infectați pe regiuni (Densitatea acestor regiuni)



Sisteme inteligente – SIS – Învățare automată

□ Proiectare → Alegerea funcției obiectiv

■ Care este funcția care trebuie învățată?

- Ex.: pentru jocul de dame → funcție care:
 - alege următoarea mutare
 - evaluează o mutare
- obiectivul fiind alegerea celei mai bune mutări

■ Reprezentarea funcției obiectiv


- Diferite reprezentări
 - Tablou (tabel)
 - Reguli simbolice
 - Funcție numerică
 - Funcții probabilistice
- Ex. Jocul de dame
 - Combinație liniară a nr. de piese albe, nr. de piese negre, nr. de piese albe compromise la următoarea mutare, r. de piese albe compromise la următoarea mutare
- Există un compromis între
 - expresivitatea reprezentării și
 - ușurința învățării
- Calculul funcției obiectiv
 - Timp polinomial
 - Timp non-polinomial

Sisteme inteligente – SIS – Învățare automată

- Proiectare → Alegerea unui algoritm de învățare
 - Algoritmul
 - folosind datele de antrenament
 - induce definirea unor ipoteze care
 - să se potrivească cu acestea și
 - să generalizeze cât mai bine datele ne-văzute (datele de test)
 - Principiul de lucru de bază
 - Minimizarea unei erori (funcție de cost – loss function)
 - Tipuri de algoritmi după metodologia de învățare automată
 - Învățare supervizată
 - Ex. regresie, clasificare
 - Învățare nesupervizată
 - Ex. clusterizare, reducerea numărului de dimensiuni
 - Învățare prin întărire
 - Ex. planning, gaming

Sisteme inteligente – SIS – Învățare automată



- Proiectare → Alegerea unui algoritm de învățare → Tipuri de algoritmi după metodologia de învățare automată
 - Învățare supervizată
 - Ex. regresie, clasificare
 - Caracteristici
 - Date etichetate (se cunosc o parte din datele de intrare și ieșire *)
 - Feedback direct în timpul învățării – algoritmul se adaptează la datele de intrare și ieșire
 - Predicție a datelor de ieșire (fiind cunoscute niște date de intrare diferite de cele din *)



)

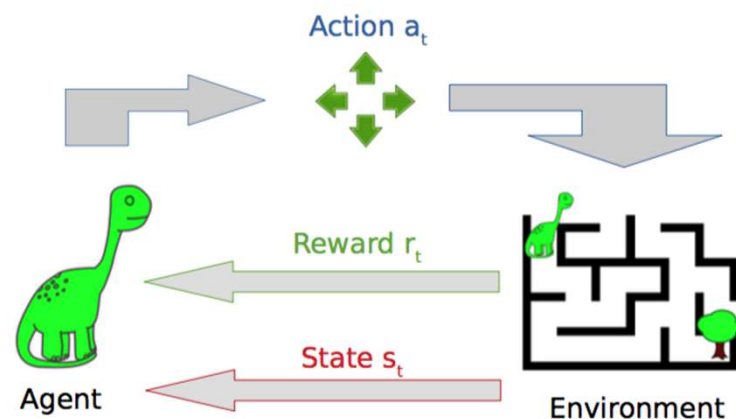
Sisteme inteligente – SIS – Învățare automată

- Proiectare → Alegerea unui algoritm de învățare → Tipuri de algoritmi după metodologia de învățare automată
 - Învățare supervizată
 - Învățare nesupervizată
 - Ex. clusterizare, reducerea numărului de dimensiuni
 - Caracteristici
 - Date neetichetate (se cunosc o parte din datele de intrare**)
 - Fără feedback direct în timpul învățării – pentru că nu se cunosc datele de ieșire
 - Identificarea unor structuri în date (generarea de date de ieșire pentru datele de intrare din **)



Sisteme inteligente – SIS – Învățare automată

- Proiectare → Alegerea unui algoritm de învățare → Tipuri de algoritmi după metodologia de învățare automată
 - Învățare supervizată
 - Învățare nesupervizată
 - Învățare prin întărire
 - Ex.
 - Caracteristici
 - Predicția unor secvențe de decizii / de acțiuni
 - Sistem de recompense (pentru fiecare decizie / acțiune)
 - Se învață un model de acțiune (o serie de acțiuni care trebuie efectuate)



Sisteme inteligente – SIS – Învățare automată

- Proiectare → Alegerea unui algoritm de învățare
 - Algoritmul
 - folosind datele de antrenament
 - induce definirea unor ipoteze care
 - să se potrivească cu acestea și
 - să generalizeze cât mai bine datele ne-văzute (datele de test)
 - Principiul de lucru de bază
 - Minimizarea unei erori (funcție de cost – loss function) pentru datele de antrenament
 - Eroarea de predicție (cât de departe sunt valorile prezise față de valorile reale)
 - Eroarea de clasificare (câte exemple au fost clasificate corect)
 - Eroarea creării unor structuri (cât de ne-omogene sunt structurile produse)
- Proiectare → Evaluarea unui sistem de învățare
 - Experimental
 - Compararea diferitelor metode pe diferite date (cross-validare)
 - Colectarea datelor pe baza performanței
 - Acuratețe, timp antrenare, timp testare
 - Aprecierea diferențelor dpdv statistic
 - Teoretic
 - Analiza matematică a algoritmilor și demonstrarea de teoreme
 - Complexitatea computațională
 - Abilitatea de a se potrivi cu datele de antrenament
 - Complexitatea eșantionului relevant pentru o învățare corectă

Sisteme inteligente – SIS – Învățare automată

- Proiectare → Evaluarea unui sistem de învățare
 - Compararea performanțelor a 2 algoritmi în rezolvarea unei probleme
 - Indicatori de performanță
 - Parametrii ai unei serii statistice (ex. media)
 - Proporție calculată pentru serie statistică (ex. acuratețea)
 - Comparare pe baza intervalelor de încredere
 - Pp o problemă și 2 algoritmi care o rezolvă
 - Performanțele algoritmilor: p_1 și p_2
 - Intervalele de încredere corespunzătoare celor 2 performanțe $I_1=[p_1-\Delta_1, p_1+\Delta_1]$ și $I_2=[p_2-\Delta_2, p_2+\Delta_2]$
 - Dacă $I_1 \cap I_2 = \emptyset \rightarrow$ algoritmul 1 este mai bun decât algoritmul 2 (pt problema dată)
 - Dacă $I_1 \cap I_2 \neq \emptyset \rightarrow$ nu se poate spune care algoritm este mai bun
 - Interval de încredere pentru medie
 - Pentru o serie statistică de volum n , cu media (calculată) m și dispersia σ să se determine intervalul de încredere al valorii medii μ
 - $P(-z \leq (m-\mu)/(\sigma/\sqrt{n}) \leq z) = 1 - \alpha \rightarrow \mu \in [m - z\sigma/\sqrt{n}, m + z\sigma/\sqrt{n}]$
 - $P = 95\% \rightarrow z = 1.96$
 - Ex. Problema rucsacului rezolvată cu ajutorul algoritmilor evolutivi
 - Interval de încredere pentru acuratețe
 - Pentru o performanță p (acuratețe) calculată pentru n date să se determine intervalul de încredere
 - $P \in [p - z(p(1-p)/n)^{1/2}, p + z(p(1-p)/n)^{1/2}]$
 - $P = 95\% \rightarrow z = 1.96$
 - Ex. Problemă de clasificare rezolvată cu ajutorul Mașinilor cu suport vectorial

$P=1-\alpha$	z
99.9%	3.3
99.0%	2.577
98.5%	2.43
97.5%	2.243
95.0%	1.96
90.0%	1.645
85.0%	1.439
75.0%	1.151

Sisteme inteligente – SIS – Învățare automată

□ Proiectare → Alegerea bazei de experiență

■ Bazată pe

□ Experiență directă

- Perechi (intrare, ieșire) utile pt. funcția obiectiv
- Ex. Jocul de dame → table de joc etichetată cu mutare corectă sau incorectă

□ Experiență indirectă

- Feedback util (diferit de perechile I/O) pt funcția obiectiv
- Ex. Jocul de dame → secvențe de mutări și scorul final asociat jocului

■ Surse de date

□ Exemple generate aleator

- Exemple pozitive și negative

□ Exemple pozitive colectate de un “învățător” benevol

□ Exemple reale

■ Compoziție

□ Date de antrenament

□ Date de test

■ Caracteristici

□ Date independente

- Dacă nu → clasificare colectivă

□ Datele de antrenament și de test trebuie să urmeze aceeași lege de distribuție

- Dacă nu → învățare prin transfer (*transfer learning/inductive transfer*)
 - recunoașterea mașinilor → recunoașterea camioanelor
 - analiza textelor
 - filtre de spam

Sisteme inteligente – SIS – Învățare automată

❑ Proiectare → Alegerea bazei de experiență

■ Tipuri de attribute ale datelor

❑ Cantitative → scară nominală sau rațională

- Valori continue → greutatea
- Valori discrete → numărul de computere
- Valori de tip interval → durata unor evenimente

❑ Calitative

- Nominale → culoarea
- Ordinale → intensitatea sunetului (joasă, medie, înaltă)

❑ Structurate

- Arbori – rădăcina e o generalizare a copiilor (vehicol → mașină, autobus, tractor, camion)

■ Transformări asupra datelor

❑ Standardizare → attribute numerice

- Înlăturarea efectelor de scară (scări și unități de măsură diferite)
- Valorile brute se transformă în scoruri z
 - $Z_{ij} = (x_{ij} - \mu_j) / \sigma_j$, unde x_{ij} – valoarea atributului al j -lea al instanței i , μ_j (σ_j) este media (abaterea) atributelor j pt. toate instanțele

❑ Selectarea anumitor attribute

Sisteme inteligente – SIS – Învățare automată

□ Învățare supervizată

- Definire
- Exemple
- Proces
- Calitatea învățării
 - Metode de evaluare
 - Măsuri de performanță
- Tipologie

Sisteme inteligente – SIS – Învățare automată


Învățare supervizată

- Scop
 - Furnizarea unei ieșiri corecte pentru o nouă intrare
- Definire
 - Se dă un set de date (exemple, instanțe, cazuri)
 - date de antrenament – sub forma unor perechi ($\text{attribute_data}_i, \text{ieșire}_i$), unde
 - $i = 1, N$ ($N = \text{nr datelor de antrenament}$)
 - $\text{attribute_data}_i = (\text{atr}_{i1}, \text{atr}_{i2}, \dots, \text{atr}_{im})$, $m = \text{nr atributelor (caracteristicilor, proprietăților) unei date}$
 - ieșire_i
 - o categorie dintr-o mulțime dată (predefinită) cu k elemente ($k = \text{nr de clase}$) → problemă de clasificare
 - un număr real → problemă de regresie
 - date de test - sub forma (attribute_data_i), $i = 1, n$ ($n = \text{nr datelor de test}$).
 - Să se determine
 - o funcție (necunoscută) care realizează corespondența atribut – ieșire pe datele de antrenament
 - ieșirea (clasa/valoarea) asociată unei date (noi) de test folosind funcția învățată pe datele de antrenament
- Alte denumiri
 - Clasificare (regresie), învățare inductivă

Sisteme inteligente – SIS – Învățare automată

Învățare supervizată

- Proces → 2 etape
 - Antrenarea
 - Învățarea, cu ajutorul unui algoritm, a modelului de predicție
 - Testarea
 - Testarea modelului folosind date de test noi (*unseen data*)



- Caracteristic
 - BD experimentală adnotată (pt. învățare)

Învățare supervizată

□ Tip de probleme

- regresie
 - Scop: predicția output-ului pentru un input nou
 - Output continuu (nr real)
 - Ex.: predicția ratei șomajului în funcție de produsul intern brut și rata inflației
- clasificare
 - Scop: clasificarea (etichetarea) unui nou input
 - Output discret (etichetă dintr-o mulțime predefinită)
 - Ex.: detectarea tumorilor maligne în imagini RMN

□ Exemple de probleme

- Recunoașterea scrisului de mână
- Recunoașterea pietonilor în imagini
- Previziunea vremii
- Detectția spam-urilor

Sisteme inteligente – SIS – Învățare automată

□ Învățare supervizată

- Terminologie – e.g. Problema predicției consumului de înghețată pe baza temperaturii de afară și a sumei de bani avută la dispoziție
 - Exemplu (example, observation, instance, record)
 - o observație a datelor care trebuie procesate
 - dacă datele de intrare sunt tabelare, un exemplu este asociat cu o linie din tabel
 - format din proprietăți a datelor care trebuie procesate (de intrare și de ieșire)
 - Caracteristică (feature, property, attribute)
 - Proprietate cunoscută a unui exemplu, folosită drept dată de intrare pentru algoritmul de ML (variabilele independente din modelul de predicție)
 - dacă datele de intrare sunt tabelare, un o proprietate are asociate valorile dintr-o coloana a tabelului (pentru toate exemplele)
 - E.g. Temperatura, banii
 - Valoare țintă (target or real value/label, ground-truth)
 - Proprietate a unui exemplu folosită ca variabilă dependentă
 - Cunoscută pentru exemplele de antrenament
 - Ne-cunoscută pentru exemplele de testare
 - E.g. Nr de inghetate
 - Valoare calculată (computed value/label)
 - Proprietate a unui exemplu estimată cu ajutorul algoritmului de ML
 - Se dorește a fi cât mai aproape de valoarea target

Exemplu	Temperatura	Banii	Nr de inghetate
Ex1	30	25	2
Ex2	5	100	0
Ex3	19	55	2
Ex4	35	75	4

Sisteme inteligente – SIS – Învățare automată

Învățare supervizată

□ Calitatea învățării

■ Definire

- o măsură de performanță a algoritmului de ML
 - ex. acuratețea ($\text{Acc} = \text{nr de exemple corect clasificate} / \text{nr total de exemple}$)
- Posibile măsuri:
 - Măsuri statistice
 - Eroarea de predicție
 - acuratețea
 - Precizia
 - Rapelul
 - Scorul F1

Sisteme inteligente – SIS – Învățare automată

Învățare supervizată

□ Calitatea învățării → Măsuri de performanță → Măsuri statistice


■ Eroarea de predicție

□ Suma diferențelor absolute între valorile reale și cele calculate

$$Err = \frac{1}{noSamples} \sum_{i=1}^{noSamples} abs(real_i - computed_i)$$

□ Suma pătratelor diferențelor între valorile reale și cele calculate

$$Err = \sqrt{\frac{1}{noSamples} \sum_{i=1}^{noSamples} (real_i - computed_i)^2}$$



Sisteme inteligente – SIS – Învățare automată

Învățare supervizată

□ Calitatea învățării → Măsurile de performanță → Măsurile statistice

■ Acuratețea

- Nr de exemple corect clasificate / nr total de exemple
- Opusul erorii
- Calculată pe
 - Setul de validare
 - Setul de test
- Uneori
 - Analiză de text
 - Detectarea intrușilor într-o rețea
 - Analize financiare

este importantă doar o singură clasă (clasă pozitivă) → restul claselor sunt negative

■ Precizia (P)

- nr. de exemple pozitive corect clasificate / nr. total de exemple clasificate ca pozitive
- probabilitatea ca un exemplu clasificat pozitiv să fie relevant
- $TP / (TP + FP)$

■ Rapelul (R)

- nr. de exemple pozitive corect clasificate / nr. total de exemple pozitive
- Probabilitatea ca un exemplu pozitiv să fie identificat corect de către clasificator
- $TP / (TP + FN)$
- Matrice de confuzie → rezultate reale vs. rezultate calculate

■ Scorul F1

- Combină precizia și rapelul, facilitând compararea a 2 algoritmi
- Media armonică a preciziei și rapelului
- $2PR / (P + R)$

		Rezultate reale	
		Clasa pozitivă	Clasa(e) negativă(e)
Rezultate calculate	Clasa pozitivă	<i>True positiv (TP)</i>	<i>False positiv (FP)</i>
	Clasa(e) negativă(e)	<i>False negative (FN)</i>	<i>True negative (TN)</i>

Sisteme inteligente – SIS – Învățare automată

Învățare supervizată

Calitatea învățării → Măsuri de performanță → Măsuri statistice

- Acuratețea
 - Nr de exemple corect clasificate / nr total de exemple
- Precizia (P)
 - nr. de exemple pozitive corect clasificate / nr. total de exemple clasificate ca pozitive
 - probabilitatea ca un exemplu clasificat pozitiv să fie relevant
 - $TP / (TP + FP)$
- Rapelul (R)
 - nr. de exemple pozitive corect clasificate / nr. total de exemple pozitive
 - Probabilitatea ca un exemplu pozitiv să fie clasificat corect
 - $TP / (TP + FN)$
 - Matrice de confuzie → rezultate re
- Scorul F1
 - Combină precizia și rapelul, facilită combinarea a 2 algoritmi
 - Media armonică a preciziei și rapelului
 - $2PR / (P + R)$

		Rezultate reale	
		Clasa pozitivă	Clasa(e) negativă(e)
Rezultate calculate	Clasa pozitivă	True positiv (TP)	False positiv (FP)
	Clasa(e) negativă(e)	False negative (FN)	True negative (TN)



Sisteme inteligente – SIS – Învățare automată

Învățare supervizată

□ Calitatea învățării

■ Definire

- o măsură de performanță a algoritmului
 - ex. acuratețea ($\text{Acc} = \text{nr de exemple corect clasificate} / \text{nr total de exemple}$)
- Posibile măsuri:
 - Măsuri statistice
 - acuratețea
 - Precizia
 - Rapelul
 - Scorul F1
 - Eficiența
 - În construirea modelului
 - În testarea modelului
 - Robustețea
 - Tratarea zgomotelor și a valorilor lipsă
 - Scalabilitatea
 - Eficiența gestionării seturilor mari de date
 - Interpretabilitatea
 - Modelului de clasificare
 - Proprietatea modelului de a fi compact
 - Scoruri

Sisteme inteligente – SIS – Învățare automată

Învățare supervizată

□ Calitatea învățării

■ Definire

- o măsură de performanță a algoritmului
 - ex. acuratețea ($\text{Acc} = \text{nr de exemple corect clasificate} / \text{nr total de exemple}$)
- calculată în
 - faza de antrenare
 - faza de testare

■ Metode de evaluare

- Seturi disjuncte de antrenare și testare
 - setul de antrenare poate fi împărțit în date de învățare și date de validare
 - setul de antrenare este folosit pentru estimarea parametrilor modelului (cei mai buni parametri obținuți pe validare vor fi folosiți pentru construcția modelului final)
 - pentru date numeroase
- Validare încrucișată cu mai multe (h) sub-seturi egale ale datelor (de antrenament)
 - separarea datelor de h ori în ($h-1$ sub-seturi pentru învățare și 1 sub-set pt validare)
 - dimensiunea unui sub-set = dimensiunea setului / h
 - performanța este dată de media pe cele h rulări (ex. $h = 5$ sau $h = 10$)
 - pentru date puține
- Leave-one-out cross-validation
 - similar validării încrucișate, dar $h = \text{nr de date}$ → un sub-set conține un singur exemplu
 - pentru date foarte puține

■ Dificultăți

- Învățare pe derost (overfitting) → performanță bună pe datele de antrenament, dar foarte slabă pe datele de test

Sisteme inteligente – SIS – Învățare automată

□ Învățare ne-supervizată

- Definire
- Exemple
- Proces
- Metode de evaluare și măsuri de performanță
- Tipologie

Sisteme inteligente – SIS – Învățare automată


Învățare ne-supervizată

□ Scop

- Găsirea unui model sau a unei structuri utile a datelor
- Împărțirea unor exemple **neetichetate** în submulțimi disjuncte (clusteri) astfel încât:
 - exemplele din același cluster sunt foarte similare
 - exemplele din clusteri diferiți sunt foarte diferite

□ Definire

- Se dă un set de date (exemple, instanțe, cazuri)
 - Date de antrenament sub forma **atribute_data_i**, unde
 - $i = 1, N$ (N = nr datelor de antrenament)
 - **atribute_data_i** = ($atr_{i1}, atr_{i2}, \dots, atr_{im}$), m – nr atributelor (caracteristicilor, proprietăților) unei date
 - Date de test sub forma (**atribute_data_i**), $i = 1, n$ (n = nr datelor de test)
- Se determină
 - o funcție (necunoscută) care realizează gruparea datelor de antrenament în mai multe clase
 - Nr de clase poate fi pre-definit (k) sau necunoscut
 - Datele dintr-o clasă sunt asemănătoare
 - clasa asociată unei date (noi) de test folosind gruparea învățată pe datele de antrenament
- Învățare supervizată vs. învățare ne-supervizată



■ Distanțe între 2 elemente p și $q \in R^m$

- Euclideană $\rightarrow d(p,q) = \sqrt{\sum_{j=1,2,\dots,m} (p_j - q_j)^2}$
- Manhattan $\rightarrow d(p,q) = \sum_{j=1,2,\dots,m} |p_j - q_j|$
- Mahalanobis $\rightarrow d(p,q) = \sqrt{(p-q)^T S^{-1} (p-q)}$, unde S este matricea de variație și covariație ($S = E[(p-E[p])(q-E[q])]$)
- Produsul intern $\rightarrow d(p,q) = \sum_{j=1,2,\dots,m} p_j q_j$
- Cosine $\rightarrow d(p,q) = \sum_{j=1,2,\dots,m} p_j q_j / (\sqrt{\sum_{j=1,2,\dots,m} p_j^2} * \sqrt{\sum_{j=1,2,\dots,m} q_j^2})$
- Hamming \rightarrow numărul de diferențe între p și q
- Levenshtein \rightarrow numărul minim de operații necesare pentru a-l transforma pe p în q

■ Distanță vs. Similaritate

- Distanța \rightarrow min
- Similaritatea \rightarrow max

Sisteme inteligente – SIS – Învățare automată

Învățare ne-supervizată

- ❑ Alte denumiri
 - Clustering
- ❑ Procesul → 2 pași
 - Antrenarea → Învățarea (determinarea), cu ajutorul unui algoritm, a clusterilor existenți
 - Testarea → Plasarea unei noi date într-unul din clusterii identificați în etapa de antrenament
- ❑ Caracteristic
 - Datele nu sunt adnotate (etichetate)
- ❑ Tip de probleme
 - Identificarea unor grupuri (clusteri)
 - ❑ Analiza genelor
 - ❑ Procesarea imaginilor
 - ❑ Analiza rețelelor sociale
 - ❑ Segmentarea pieței
 - ❑ Analiza datelor astronomice
 - ❑ Clusteri de calculatoare
 - Reducerea dimensiunii
 - Identificarea unor cauze (explicații) ale datelor
 - Modelarea densității datelor
- ❑ Exemple de probleme
 - Gruparea genelor
 - Studii de piață pentru gruparea clienților (segmentarea pieței)
 - news.google.com

Sisteme inteligente – SIS – Învățare automată

Învățare ne-supervizată

- ❑ Calitatea învățării (validarea clusterizării):
 - Criterii interne → Similaritate ridicată în interiorul unui cluster și similaritate redusă între clusteri
 - ❑ Distanța în interiorul clusterului
 - ❑ Distanța între clusteri
 - ❑ Indexul Davies-Bouldin
 - ❑ Indexul Dunn
 - Criterii externe → Folosirea unor benchmark-uri formate din date pre-grupate
 - ❑ Compararea cu date cunoscute – în practică este imposibil
 - ❑ Precizia
 - ❑ Rapelul
 - ❑ F-measure

Sisteme inteligente – SIS – Învățare automată

Învățare ne-supervizată

■ Calitatea învățării → Criterii interne

■ Distanța în interiorul clusterului c_j care conține n_j instanțe

- Distanța medie între instanțe (average distance) $D_a(c_j) = \sum_{x_{i1}, x_{i2} \in c_j} ||x_{i1} - x_{i2}|| / (n_j(n_j-1))$
- Distanța între cei mai apropiați vecini $D_{nn}(c_j) = \sum_{x_{i1} \in c_j} \min_{x_{i2} \in c_j} ||x_{i1} - x_{i2}|| / n_j$
- Distanța între centroizi $D_c(c_j) = \sum_{x_i \in c_j} ||x_i - \mu_j|| / n_j$, unde $\mu_j = 1/n_j \sum_{x_i \in c_j} x_i$

■ Distanța între 2 clusteri c_{j1} și c_{j2}

- Legătură simplă $d_s(c_{j1}, c_{j2}) = \min_{x_{i1} \in c_{j1}, x_{i2} \in c_{j2}} \{ ||x_{i1} - x_{i2}|| \}$
- Legătură completă $d_{co}(c_{j1}, c_{j2}) = \max_{x_{i1} \in c_{j1}, x_{i2} \in c_{j2}} \{ ||x_{i1} - x_{i2}|| \}$
- Legătură medie $d_a(c_{j1}, c_{j2}) = \sum_{x_{i1} \in c_{j1}, x_{i2} \in c_{j2}} \{ ||x_{i1} - x_{i2}|| \} / (n_{j1} * n_{j2})$
- Legătură între centroizi $d_{ce}(c_{j1}, c_{j2}) = ||\mu_{j1} - \mu_{j2}||$

■ Indexul Davies-Bouldin → min → clusteri compacți

- $DB = 1/nc * \sum_{i=1,2,...,nc} \max_{j=1,2,...,nc, j \neq i} ((\sigma_i + \sigma_j)/d(\mu_i, \mu_j))$, unde:
 - nc – numărul de clusteri
 - μ_i – centroidul clusterului i
 - σ_i – media distanțelor între elementele din clusterul i și centroidul μ_i
 - $d(\mu_i, \mu_j)$ – distanța între centroidul μ_i și centroidul μ_j

■ Indexul Dunn

- Identifică clusterii denși și bine separați
- $D = d_{min}/d_{max}$, unde:
 - d_{min} – distanța minimă între 2 obiecte din clusteri diferiți – distanța intra-cluster
 - d_{max} – distanța maximă între 2 obiecte din același cluster – distanța inter-cluster

Sisteme inteligente – SIS – Învățare automată

Învățare ne-supervizată

□ Tipologie

■ După modul de formare al clusterilor

□ Ierarhic

- se crează un arbore taxonomic (dendogramă)
 - crearea clusterilor → recursiv
 - nu se cunoaște k (nr de clusteri)
- aglomerativ (de jos în sus) → clusteri mici spre clusteri mari
- diviziv (de sus în jos) → clusteri mari spre clusteri mici
- Ex. Clustering ierarhic aglomerativ

□ Ne-ierarhic

- Partițional → se determină o împărțire a datelor → toți clusterii deodată
- Optimizează o funcție obiectiv definită local (doar pe anumite atribute) sau global (pe toate atributele) care poate fi:
 - Pătratul erorii – suma patratelor distanțelor între date și centroizii clusterilor → min (ex. K-means)
 - Bazată pe grafuri (ex. Clusterizare bazată pe arborele minim de acoperire)
 - Pe modele probabilistice (ex. Identificarea distribuției datelor → Maximizarea așteptărilor)
 - Pe cel mai apropiat vecin
- Necesită fixarea apriori a lui k → fixarea clusterilor inițiali
 - Algoritmii se rulează de mai multe ori cu diferiți parametri și se alege versiunea cea mai eficientă
- Ex. K-means, ACO

□ bazat pe densitatea datelor

- Densitatea și conectivitatea datelor
 - Formarea clusterilor de bazează pe densitatea datelor într-o anumită regiune
 - Formarea clusterilor de bazează pe conectivitatea datelor dintr-o anumită regiune
- Funcția de densitate a datelor
 - Se încearcă modelarea legii de distribuție a datelor
- Avantaj:
 - Modelarea unor clusteri de orice formă

□ Bazat pe un grid

- Nu e chiar o metodă nouă de lucru
 - Poate fi ierarhic, partițional sau bazat pe densitate
- Pp segmentarea spațiului de date în zone regulate
- Obiectele se plasează pe un grid multi-dimensional
- Ex. ACO

Sisteme inteligente – SIS – Învățare automată

Învățare ne-supervizată

□ Tipologie

■ După modul de lucru al algoritmului

□ Aglomerativ

1. Fiecare instanță formează inițial un cluster
2. Se calculează distanțele între oricare 2 clusteri
3. Se reunesc cei mai apropiați 2 clusteri
4. Se repetă pașii 2 și 3 până se ajunge la un singur cluster sau la un alt criteriu de stop

□ Diviziv

1. Se stabilește numărul de clusteri (k)
2. Se inițializează centrul fiecărui cluster
3. Se determină o împărțire a datelor
4. Se recalculează centrul clusterelor
5. Se repetă pasul 3 și 4 până partiționarea nu se mai schimbă (algoritmul a converș)

■ După attributele considerate

- Monotetic – attributele se consideră pe rând
- Politetic – attributele se consideră simultan

■ După tipul de apartenență al datelor la clusteri

□ Clustering exact (*hard clustering*)

- Asociază fiecărei intrări x_i o etichetă (clasă) c_j

□ Clustering fuzzy

- Asociază fiecărei intrări x_i un grad (probabilitate) de apartenență f_{ij} la o anumită clasă $c_j \rightarrow$ o instanță x_i poate aparține mai multor clusteri

Sisteme inteligente – SIS – Învățare automată

□ Tipologie

- În funcție de experiența acumulată în timpul învățării
 - SI cu învățare supervizată
 - SI cu învățare nesupervizată
 - **SI cu învățare activă**
 - SI cu învățare cu întărire
- În funcție de modelul învățat (algoritmul de învățare)
 - Arbori de decizie
 - Rețele neuronale artificiale
 - Algoritmi evolutivi
 - Mașini cu suport vectorial
 - Modele Markov ascunse

Sisteme inteligente – SIS – Învățare automată

□ Învățare activă

- Algoritmul de învățare poate primi informații suplimentare în timpul învățării pentru a-și îmbunătăți performanța

- Ex. pe care din datele de antrenament este mai ușor să se învețe modelul de decizie




Figure 1.1: General schema for a passive learner.



Figure 1.2: General schema for an active learner.

Sisteme inteligente – SIS – Învățare automată

□ Tipologie

- În funcție de experiența acumulată în timpul învățării
 - SI cu învățare supervizată
 - SI cu învățare nesupervizată
 - SI cu învățare activă
 - SI cu învățare cu întărire
- În funcție de modelul învățat (algoritmul de învățare)
 - **Metoda celor mai mici pătrate**
 - Metoda gradient descent
 - Algoritmi evolutivi
 - Logistic regression
 - kNN
 - Arbori de decizie
 - Mașini cu suport vectorial
 - Rețele neuronale artificiale
 - Programare genetică
 - Modele Markov ascunse

Recapitulare



- Sisteme care învață singure (SIS)
 - Instruire (învățare) automata (Machine Learning - ML)
 - Învățare supervizată → datele de antrenament sunt deja etichetate cu elemente din E , iar datele de test trebuie etichetate cu una dintre etichetele din E pe baza unui model (învățat pe datele de antrenament) care face corespondența date-etichete
 - Învățare nesupervizată → datele de antrenament NU sunt etichetate, trebuie învățat un model de etichetare, iar apoi datele de test trebuie etichetate cu una dintre etichetele identificate de model
 - Sisteme

Cursul următor

A. Scurtă introducere în Inteligența Artificială (IA)

B. Rezolvarea problemelor prin căutare

- Definirea problemelor de căutare
- Strategii de căutare
 - Strategii de căutare neinformate
 - Strategii de căutare informate
 - Strategii de căutare locale (Hill Climbing, Simulated Annealing, Tabu Search, Algoritmi evolutivi, PSO, ACO)
 - Strategii de căutare adversarială

C. Sisteme inteligente

- Sisteme care învață singure
 - Metoda celor mai mici patrate, Gradient Descent, Logistic regression
 - Arbori de decizie
 - Rețele neuronale artificiale
 - Mașini cu suport vectorial
 - Algoritmi evolutivi
- Sisteme bazate pe reguli
- Sisteme hibride

Cursul următor – Materiale de citit și legături utile

- ❑ Capitolul VI (19) din *S. Russell, P. Norvig, Artificial Intelligence: A Modern Approach, Prentice Hall, 1995*
- ❑ capitolul 8 din *Adrian A. Hopgood, Intelligent Systems for Engineers and Scientists, CRC Press, 2001*
- ❑ capitolul 12 și 13 din *C. Groșan, A. Abraham, Intelligent Systems: A Modern Approach, Springer, 2011*
- ❑ Capitolul V din *D. J. C. MacKey, Information Theory, Inference and Learning Algorithms, Cambridge University Press, 2003*
- ❑ Capitolul 4 din *T. M. Mitchell, Machine Learning, McGraw-Hill Science, 1997*

□ Informațiile prezentate au fost colectate din diferite surse de pe internet, precum și din cursurile de inteligență artificială ținute în anii anteriori de către:

■ Conf. Dr. Mihai Oltean –
www.cs.ubbcluj.ro/~moltean

■ Lect. Dr. Crina Groșan -
www.cs.ubbcluj.ro/~cgrosan

■ Prof. Dr. Horia F. Pop -
www.cs.ubbcluj.ro/~hfpop